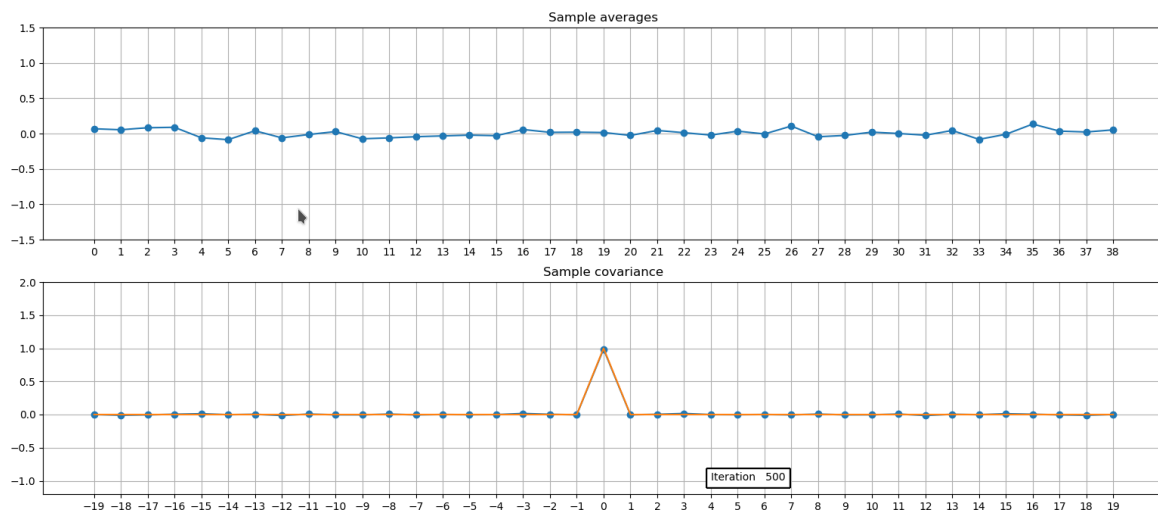


TP DE TSIA-202a

EXERCICE 1


1) White Noise:

Fonction d'autocovariance théorique en orange et pratique en bleu sur le deuxième graphe. en théorie, on a $\Gamma(t) = \{\sigma^2 \text{ si } t=0 \text{ et } 0 \text{ sinon}\}$




2) AR process:

Fonction d'autocovariance théorique en orange et pratique en bleu sur le deuxième graphe. en théorie, on a $\Gamma(t) = \phi^{**|t|} / (1 - \phi^{**2})$



3) Sinusoidal process:

Fonction d'autocovariance théorique en orange et pratique en bleu sur le deuxième graphe.
 en théorie, on a $\Gamma(t) = \begin{cases} (A^2/2) \cos(\omega_0 t) + \sigma^2 & \text{si } t=0 \\ (A^2/2) \cos(\omega_0 t) & \text{sinon} \end{cases}$



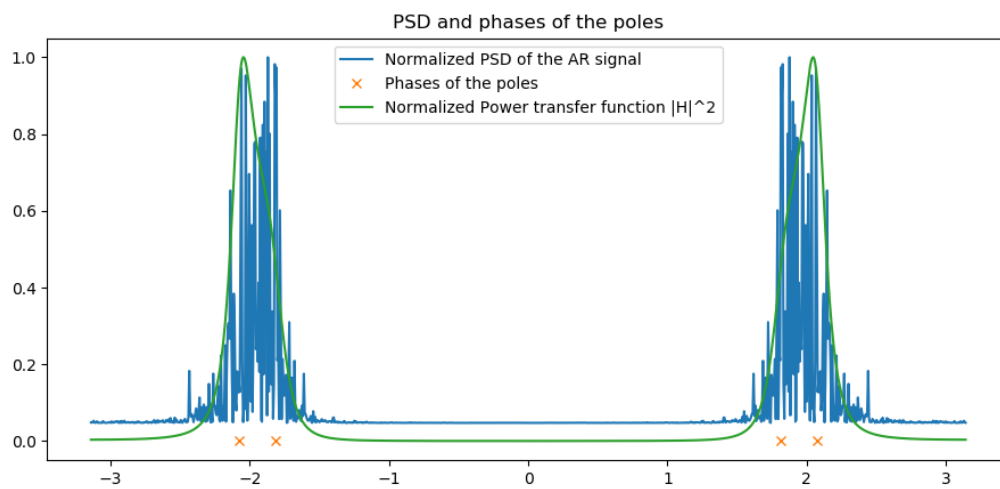
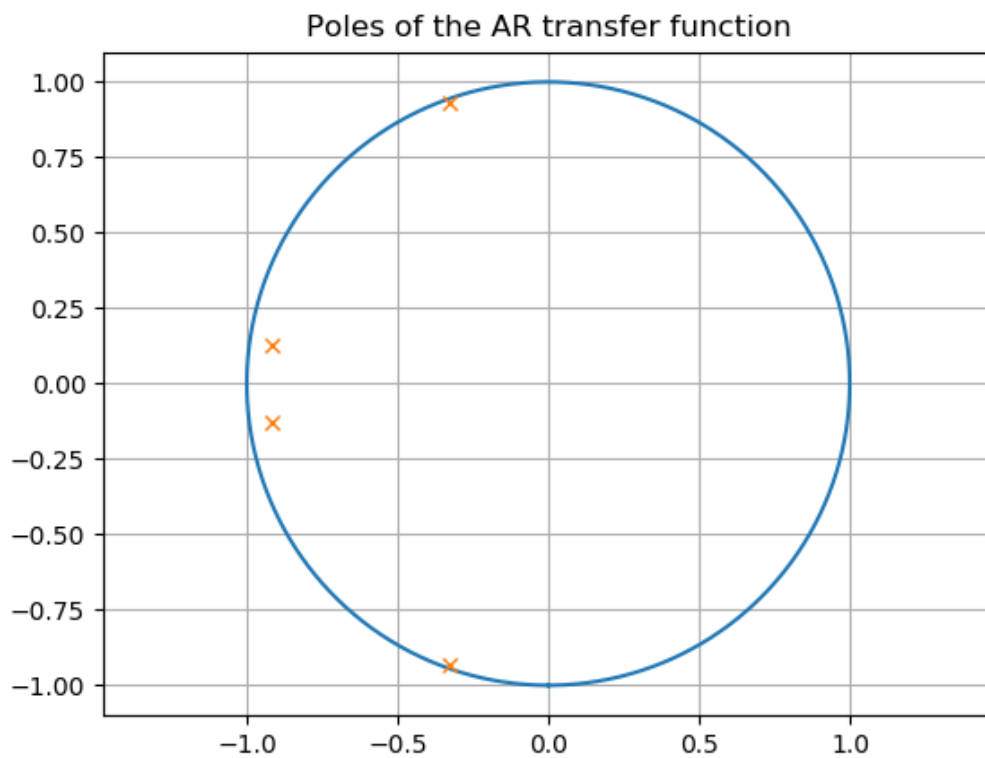
Pour les valeurs théoriques, on a utilisé le code suivant:

```

3 import numpy as np
4 import matplotlib.pyplot as plt
5
6
7
8 H=20
9 axe=np.arange(-H+1,H)
10 Y=np.zeros(len(axe))
11
12
13 sigma=1
14 A=1.0
15 w=np.pi/3
16 phi=0.6
17
18 signal='SIN' #AR ou SIN ou WN
19
20 if signal=='SIN':
21     for t in range(len(Y)):
22         Y[t]=(A**2/2)*np.cos(w*(t-H+1))
23         Y[H-1]+=sigma**2
24
25 elif signal=='AR':
26     for t in range(len(Y)):
27         Y[t]=phi**abs(t-H+1)/(1-phi**2)
28
29 else:
30     Y[H-1]=sigma**2
31
32 plt.plot(axe,Y)

```

Pour le filtre AR, on obtient avec la fonction `rp.drawZ_DTFT_AR` :



EXERCICE 2

Q1.

$$\begin{aligned}
 1) \text{ On a : } I_n(\lambda) &= \frac{1}{2\pi} \sum_{k=-n+1}^{n-1} \hat{\gamma}_n(k) e^{-i\lambda h} \\
 &= \frac{1}{2\pi} \sum_{k=-n+1}^{n-1} \left(\sum_{t=0}^{n-1-k} \frac{1}{n} (X_t - \hat{\mu}_n)(X_{t+k} - \hat{\mu}_n) \right) e^{-i\lambda h} \\
 &= \frac{1}{2\pi n} \times \left(\sum_{k=0}^{n-1} \sum_{j=0}^{n-1} (X_k - \hat{\mu}_n)(X_j - \hat{\mu}_n) e^{-i\lambda(k-j)} \right) \\
 &= \frac{1}{2\pi n} \sum_{k=0}^{n-1} (X_k - \hat{\mu}_n) e^{-i\lambda k} \sum_{j=0}^{n-1} (X_j - \hat{\mu}_n) e^{+i\lambda j}
 \end{aligned}$$

On note \hat{X} la DFT de $X_0 - \hat{\mu}_n, \dots, X_{n-1} - \hat{\mu}_n$

On a $\hat{X}(\lambda) = \frac{1}{2\pi} \sum_{k=0}^{n-1} (X_k - \hat{\mu}_n) e^{-i\lambda k}$

Donc $I_n(\lambda) = \frac{2\pi}{n} \times \hat{X}(\lambda) \times \overline{\hat{X}(\lambda)}$

Donc $I_n(\lambda) = \frac{2\pi}{n} |\hat{X}(\lambda)|^2$

Q2.


on utilise le code suivant pour la fonction I:

```


def I(X,m):
    L=np.arange(m)
    n=len(X)
    moy=0
    for x in X:
        moy+=x
    moy=moy/n
    for k in range(m):
        tftd=0
        for i in range(n):
            tftd+=(X[k]-moy)*np.exp(-2j*np.pi*k*i/m)
        tftd=tftd/(2*np.pi)
        L[k]=(2*np.pi/n)*abs(tftd)**2
    return L

```


On obtient en testant la fonction:



pour WN:



pour AR:



pour SIN:

Q3.

$$\text{On a } I_n\left(2\pi \frac{k}{m}\right) = \frac{1}{2\pi} \sum_{h=-n+1}^{n-1} \hat{\gamma}_n(h) e^{-2i\pi \frac{kh}{m}}$$

Donc si $m = 2n-1$, en appliquant la TFTD inverse, on obtient :

$$\hat{\gamma}_n(h) = \frac{2\pi}{2n-1} \sum_{k=-n+1}^{n-1} I_n\left(2\pi \frac{k}{2n-1}\right) e^{2i\pi \frac{kh}{2n-1}}$$


Avec le code suivant, on affiche le résultat de l'autocovariance obtenue avec la fonction `acovb` que l'on compare avec l'autocovariance théorique, on remarque que sur un échantillon de 20 valeurs, les résultats sont déjà relativement proche de ce qui est attendu:

```


75
76 cov=acovb(X)
77 axe=np.arange(len(cov))
78 plt.plot(axe,cov)
79
80 Y=np.zeros(len(cov))
81
82 if signal=='SIN':
83     for t in range(len(Y)):
84         Y[t]=(A**2/2)*np.cos(w*(t))
85     Y[0]+=sigma**2
86
87 elif signal=='AR':
88     for t in range(len(Y)):
89         Y[t]=phi**abs(t)/(1-phi**2)
90
91 else:
92     Y[0]=sigma**2
93
94 plt.plot(axe,Y)
95
96 |
97 plt.show
98

```


pour WN:



pour AR:



pour SIN:



Q4.

EXERCICE 3

Partie 1 - Yule-Walker equation

Q1.

$$x_t = \varphi_1 x_{t-1} + \varphi_2 x_{t-2} + \dots + \varphi_p x_{t-p} + z_t, \quad z_t \text{ iid}(0, \sigma^2)$$

$$\begin{aligned} E(x_{t-h} z_t) &= E(\varphi_1 x_{t-h-1} z_t + \varphi_2 x_{t-h-2} z_t + \dots + \varphi_p x_{t-h-p} z_t + z_{t-h} z_t) \\ &= \sum_{i=1}^p \varphi_i E(x_{t-h-i} z_t) + E(z_{t-h} z_t) \end{aligned}$$

Let's compute x_{t-i} for $i \leq p$. $= 0$ because white noise

$$x_{t-(p-1)} = \varphi_p x_{t-p} + z_t$$

$$x_{t-(p-2)} = (\varphi_{p-1} \varphi_p + \varphi_p) x_{t-p} + z_t$$

$$\vdots$$

$$x_{t-i} = \varphi_i x_{t-p} + z_t$$

Then $x_{t-p} = \alpha_{t-p} x_0 + z_t$. Therefore we can rewrite all x_{t-i} as $\alpha_{t-i} x_0 + z_t$.

$$\text{Then } E(x_{t-h} z_t) = \alpha_{t-h} E(x_0 z_t) + 0.$$

Since x_t is causal, $x_0 = 0 + 0 + \dots + 0 + z_0$.

$$\text{Finally, } E(x_{t-h} z_t) = \alpha_{t-h} E(z_0 z_t) = 0.$$

Q2.

$$\text{We have } \gamma(h) = E(x_{t-h} x_t) - \underbrace{E(x_{t-h})}_{=0} \underbrace{E(x_t)}_{=0}$$

$$\gamma(h) = E\left(\sum_{i=1}^p \varphi_i x_{t-h-i} \cdot x_{t-h} + z_{t-h} x_t\right) = \sum_{i=1}^p \varphi_i E(x_{t-h-i} x_t) + \underbrace{E(z_{t-h} x_t)}_{=0}$$

$$= \gamma(h-i)$$

$$\Rightarrow \gamma(h) = \sum_{i=1}^p \varphi_i \gamma(h-i)$$

Q3.

$$\text{for } h=0, \gamma(0) = E(X_t X_t) = E(X_t^2) = E(X_0^2) = E\left(\sum_{i=1}^p \varphi_i X_{-i} X_0 + z_0\right)$$

$$= \sum_{i=1}^p \varphi_i E(X_{-i} X_0) + E(X_0 z_0)$$

$$\gamma(0) = \sum_{i=1}^p \varphi_i \gamma(-i) + \sigma^2.$$

Q4.

$$\begin{cases} \gamma(h) = \sum_{i=1}^p \varphi_i \gamma(h-i) & \forall h \geq 1 \\ \gamma(0) = \sigma^2 + \sum_{i=1}^p \varphi_i \gamma(-i) \end{cases}$$

$$\text{Then } \Gamma_{p+1} = \begin{pmatrix} \gamma(0) & \gamma(-1) & \dots & \gamma(-p) \\ \gamma(1) & \gamma(0) & \dots & \gamma(1-p) \\ & & \ddots & \\ \gamma(p) & \gamma(p-1) & \dots & \gamma(0) \end{pmatrix} \begin{pmatrix} 1 \\ -\varphi_1 \\ \vdots \\ -\varphi_p \end{pmatrix} = \begin{pmatrix} \gamma(0) - \sum_{i=1}^p \varphi_i \gamma(-i) \\ \gamma(1) - \sum_{i=1}^p \varphi_i \gamma(1-i) \\ \vdots \\ \gamma(p) - \sum_{i=1}^p \varphi_i \gamma(p-i) \end{pmatrix} = \begin{pmatrix} \sigma^2 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

Partie 2 - Estimation

Q1 & Q2.

On génère un processus AR-4 de longueur $N = 1000$ à l'aide de la fonction $[X, a] = \text{genAR}(p, N)$. On utilise la fonction `acovb` pour générer la séquence des autocovariances biaisées et on déduit une estimation $\text{Gamma}_{n,p+1}$ de Gamma_{p+1} .

```
[X, a] = genAR(4, 1000)
np.mean(X)

gamma = rp.acovb(X)

Gamma_hat = la.toeplitz(gamma[:p+1])
print(Gamma_hat)
```

Q3.

$$\text{On a } \hat{r}_{n,p+1} \begin{bmatrix} 1 \\ -\varphi_1 \\ \vdots \\ -\varphi_p \end{bmatrix} = \begin{bmatrix} \sigma^2 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \sigma^2 \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$\Rightarrow \frac{1}{\sigma^2} \begin{bmatrix} 1 \\ -\varphi_1 \\ \vdots \\ -\varphi_p \end{bmatrix} = \hat{r}_{n,p+1}^{-1} \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$\Rightarrow \frac{1}{\sigma^2} = v[0] \Rightarrow \sigma^2 = \frac{1}{v[0]}$$

$$\text{Puis } (\varphi_i)_{i \in [0,p)} = v[i] \times \sigma^2.$$

Voici le code correspondant:

```
[X,a] =genAR(4,1000)

gamma = rp.acovb(X)

Gamma_hat = la.toeplitz(gamma[:p+1])
#print(Gamma_hat)
Gamma_hat_inv=la.inv(Gamma_hat)

v1 = np.zeros(p+1)
v1[0]=1

v=np.dot(Gamma_hat_inv,v1)

sigma2Est = 1/v[0]
estimated_coeff= [v[i]*sigma2Est for i in range(1,p+1)]

print(estimated_coeff )
print(sigma2Est)

[-1.3110978654547587, 0.9235659209371755, -0.7763309708007593, 0.3127765341065186]
0.9861260320945275
```

L'erreur relative est $(1-0.986)=1,4\%$.

#Compare to the poles ?

Partie 3- Application to speech signal